

第一次实验报告：卷积神经网络

姓名：_____ 学号：_____

1 实验目的

- 掌握卷积神经网络的基本原理与常用模块（卷积、池化、激活、全连接）。
- 使用 PyTorch 在 CIFAR10 数据集上完成图像分类任务。
- 对比原始 CNN 与个人实现 ResNet、DenseNet、MobileNet 在训练过程和性能上的差异。
- 扩展实现 Res2Net，并分析其相对优势与不足。

2 实验环境

- 操作系统：Windows
- Python：3.8
- 深度学习框架：PyTorch
- 主要依赖：torchvision、matplotlib
- 硬件：NVIDIA GPU（CUDA 可用）
- 数据集：CIFAR10
- 本次结果对应训练轮次：20 epoch（用于得到更稳定结论）

3 模型结构与训练结果

3.1 CNN

网络结构关键部分：

```

1 CNN(
2     (conv1): Conv2d(3, 6, kernel_size=(5, 5), stride=(1, 1))
3     (pool): MaxPool2d(kernel_size=2, stride=2)
4     (conv2): Conv2d(6, 16, kernel_size=(5, 5), stride=(1, 1))
5     (fc1): Linear(in_features=400, out_features=120, bias=True)
6     (fc2): Linear(in_features=120, out_features=84, bias=True)
7     (fc3): Linear(in_features=84, out_features=10, bias=True)
8 )

```

Listing 1: CNN 网络结构

设计思路解析：该网络为经典的 LeNet-5 变体，采用“卷积-池化-卷积-池化-全连接”的堆叠结构。由于 CIFAR10 图像尺寸为 32×32 ，经过两次 5×5 卷积（无 padding）和 2×2 池化后，特征图尺寸从 $32 \rightarrow 28 \rightarrow 14 \rightarrow 10 \rightarrow 5$ ，最终得到 $16 \times 5 \times 5$ 的特征图。这种设计计算量小、易于理解，但由于缺乏跳跃连接，深层梯度易消失，限制了性能上限。

训练/验证 loss 曲线和准确率曲线如图1和图2所示。




图 1: CNN Loss 曲线




图 2: CNN Accuracy 曲线

结果：

- 参数量：62006
- 最佳轮次：20
- 验证集最佳准确率：0.6914
- 测试集准确率：0.6754

网络结构说明：采用 BasicBlock 残差单元，包含 shortcut 跳跃连接，整体为 4 个 stage（通道 64/128/256/512）。

设计思路解析：ResNet 的核心创新是残差连接（skip connection）。通过将输入 x 直接加到卷积输出 $F(x)$ 上，形成 $F(x)+x$ ，网络学习的是残差函数而非原始映射。这使得梯

度可以直接通过 shortcut 反向传播，有效缓解了深层网络的梯度消失问题。代码中使用 BatchNorm 加速收敛，当 stride $\neq 1$ 或通道数变化时，shortcut 采用 1×1 卷积进行维度匹配。训练/验证 loss 曲线和准确率曲线如图3和图4所示。




图 3: ResNet Loss 曲线




图 4: ResNet Accuracy 曲线

结果：

- 参数量：11173962
- 最佳轮次：19
- 验证集最佳准确率：0.9178
- 测试集准确率：0.9112

3.2 DenseNet

网络结构说明：使用 DenseLayer + DenseBlock + Transition，特征在通道维持续拼接，实现特征复用。

设计思路解析：DenseNet 的核心思想是密集连接——每一层都接收前面所有层的特征图，并在通道维进行拼接。这种方式实现了特征的高效复用，缓解了梯度消失问题，同时参数量较少。growth_rate 控制每层新增的通道数，bottleneck (1×1 卷积) 先降维再升维，有效控制计算量。Transition 层通过 1×1 卷积和平均池化进行下采样和通道压缩。

训练/验证 loss 曲线和准确率曲线如图5和图6所示。




图 5: DenseNet Loss 曲线




图 6: DenseNet Accuracy 曲线

结果:

- 参数量: 180650
- 最佳轮次: 18
- 验证集最佳准确率: 0.8756
- 测试集准确率: 0.8607

3.3 MobileNet (个人实现)

网络结构说明: 采用 Depthwise Separable Convolution (深度卷积 + 逐点卷积), 在保证一定精度下显著减少计算量。

设计思路解析: MobileNet 的核心是深度可分离卷积, 它将标准卷积分解为两步: 深度卷积 (Depthwise Conv) 对每个输入通道独立做空间卷积, 计算量从 $D_K \cdot D_K \cdot M \cdot N \cdot D_F \cdot D_F$ 降为 $D_K \cdot D_K \cdot M \cdot D_F \cdot D_F + M \cdot N \cdot D_F \cdot D_F$, 理论上可减少约 $1/N + 1/D_K^2$ 的计算量。这种设计在保持较好精度的同时大幅降低参数量和计算成本, 非常适合移动端部署。

训练/验证 loss 曲线和准确率曲线如图7和图8所示。



图 7: MobileNet Loss 曲线




图 8: MobileNet Accuracy 曲线

结果：

- 参数量：543050
- 最佳轮次：19
- 验证集最佳准确率：0.8408
- 测试集准确率：0.8359

3.4 Res2Net (扩展, 个人实现)

网络结构说明：在残差块内部引入多尺度分支 (Res2Block)，将通道分组后逐级融合，从而在单个 block 中增强尺度表达能力。

设计思路解析：Res2Net 在单个残差块内部构建了层级化的多尺度表示。它将输入特征图在通道维拆分为多个子组，第一个子组直接传递，后续子组依次经过 3×3 卷积并与前一组结果相加，形成“层级递进”的多尺度融合。这种方式比标准 ResNet 在每个 block 中拥有更丰富的感受野组合，在增加少量参数的前提下提升了多尺度特征表达能力。

训练/验证 loss 曲线和准确率曲线如图9和图10所示。




图 9: Res2Net Loss 曲线




图 10: Res2Net Accuracy 曲线

结果：

- 参数量：1013130
- 最佳轮次：19
- 验证集最佳准确率：0.9012
- 测试集准确率：0.8960

4 对比分析

4.1 指标对比

表 1: 各模型性能对比

模型	参数量	最佳验证准确率	测试准确率
CNN	62006	0.6914	0.6754
ResNet	11173962	0.9178	0.9112
DenseNet	180650	0.8756	0.8607
MobileNet	543050	0.8408	0.8359
Res2Net	1013130	0.9012	0.8960

4.2 收敛速度与训练稳定性

在 20 epoch 设置下, ResNet 与 Res2Net 都表现出较快且稳定的收敛过程。DenseNet 在中后期继续稳步提升, 最终精度接近高性能模型。MobileNet 收敛稳定、震荡较小, 但最终精度略低于 ResNet/Res2Net/DenseNet。老师原始 CNN 作为基线模型收敛最慢且精度下限明显。

原因分析: ResNet 的残差连接允许梯度直接回传, 解决了深层网络的梯度消失问题; Res2Net 继承了残差连接的优势, 同时多尺度分支提升了特征表达能力; DenseNet 的密集连接实现了特征复用和梯度流动增强; MobileNet 的深度可分离卷积降低了参数量, 但特征提取能力相对受限; 普通 CNN 缺乏跳跃连接, 梯度随层数加深逐渐消失, 训练困难。

4.3 泛化能力

ResNet (0.9178 vs 0.9112) 与 Res2Net (0.9012 vs 0.8960) 验证/测试差距都较小, 泛化能力优秀。DenseNet (0.8756 vs 0.8607) 和 MobileNet (0.8408 vs 0.8359) 同样保持良好泛化。CNN (0.6914 vs 0.6754) 虽有提升, 但受限于结构容量, 整体上限较低。

4.4 参数量与性能权衡

- **ResNet:** 精度最高 (91.12%), 但参数量最大 (约 1117 万), 适合对精度要求高且计算资源充足的场景。
- **Res2Net:** 在约 101 万参数下达到接近 ResNet 的精度 (89.60%), 参数效率突出, 性价比最优。

- **DenseNet**: 参数量仅 18 万，却达到 86.07% 的精度，参数效率极高，适合参数受限场景。
- **MobileNet**: 参数量 54 万，精度 83.59%，轻量化设计使其适合移动端部署。
- **CNN**: 参数最少（6.2 万）但精度最低，更适合作为教学与基线模型。

4.5 结论性比较

1. 无跳跃连接 CNN 相比残差类模型更难优化，收敛慢且最终精度低。
2. ResNet 在本实验中取得最高准确率，是精度最优方案。
3. Res2Net 在较低参数量下取得接近 ResNet 的性能，综合性价比较高。
4. DenseNet 通过特征复用获得了较高精度，且参数效率良好。
5. MobileNet 在轻量部署场景更有优势，但精度相对略低。

5 扩展：Res2Net

- **网络结构简述**: 在残差块内部将特征通道划分为多个分支并逐级融合，增强多尺度表达能力。
- **实验结果**:
 - 参数量: 1013130
 - 最佳验证准确率: 0.9012
 - 测试准确率: 0.8960
- **与 ResNet / DenseNet / MobileNet 的优劣对比**:
 - 相比 ResNet: 精度略低 (89.60% vs 91.12%)，但参数量显著更小 (101 万 vs 1117 万)，参数效率更高。
 - 相比 DenseNet: 精度更高 (89.60% vs 86.07%)，但参数量更大 (101 万 vs 18 万)。
 - 相比 MobileNet: 精度更高 (89.60% vs 83.59%)，但模型更重、部署成本更高。

6 总结

本次实验完整实现并对比了四类卷积神经网络，并额外完成了 Res2Net 扩展实验。将训练轮次提升到 20 epoch 后，结论更加稳定：ResNet 仍是最高精度模型，Res2Net 在参数效率上表现突出，DenseNet 与 MobileNet 分别在精度与轻量化维度提供了有价值的折中方案。通过本实验，我进一步掌握了 PyTorch 下从模型构建、训练验证、可视化到结果分析的完整流程，也理解了“精度-参数量-计算开销”之间的工程权衡关系。

训练流程关键技术总结：

- 数据增强：随机裁剪（padding=4）和随机水平翻转，提升模型泛化能力
- 优化器：SGD with Nesterov momentum (0.9)，weight decay ($5e-4$)
- 学习率调度：CosineAnnealingLR，逐步衰减至 0
- 训练策略：验证集最优模型保存，避免过拟合